鉴真全域 VeriScope AI 作品介绍

> 大模型幻觉检测、证据追踪与质量门禁平台

材料日期：2026-10-05。已完成工作与本轮新实验的状态分别说明。

项目解决的问题

RAG 检索到了文档，回答中的每句话仍可能缺少依据；一个平均分也难以说明错误在哪里。鉴真全域 VeriScope AI 面向 RAG 应用开发与评测，把问题、检索上下文、模型回答、逐句记录、多模型指标和 Quality Gate 汇集到中文工作台，帮助使用者从结论回查证据。

已完成的产品

- 评测总览、TraceView、多模型对比、幻觉分析、评测报告与真实评测工作区。
- 文档处理、检索、模型问答、Ragas 指标、逐句溯源及报告生成的后端流程；保留 CLI、Gradio 和 FastAPI 本地入口。
- Quality Gate 展示与真实历史金融 FAIL 案例；说明样本范围、保存指标和门槛。
- 评测验证模块：人工结论与机器原判定分别呈现，核验材料绑定冻结快照版本与 SHA-256。

项目使用 React、FastAPI、LangChain、Chroma、Ragas 和已有模型服务。项目贡献集中在评测流程整合、中文证据回查、结果解释与人工核验记录；相关第三方组件和依赖按各自许可使用。

可以展示的现有证据

无密钥演示使用冻结快照 `20260930-1958`：6 个独立问题、3 个模型、18 条回答。作者 Kk 于 2026-10-05 逐条检查其中 13 条定向记录，结果为一致 3 条、存在分歧 5 条、无法确认 5 条。AI 仅辅助整理材料与定位证据，作者确认正式结论。

核验覆盖完整回答、参考答案、检索上下文、机器 Trace 和引用关系，记录抽取遗漏、拒答标签争议及证据不足。13 条是定向检查的回答记录数，不能据此计算总体准确率。历史金融 FAIL 来自另一场旧 CLI 运行，其正向上下文精度 0.7778 低于 0.8 门槛；该案例与当前 Demo 分开保存。

前端依赖准备后，已有快照可以在本地无需模型密钥、Embedding 或后端展示，不产生模型调用费用。真实评测需要另行配置环境和凭据，并产生提供方调用费用。

当前技术限制

当前后端会将相应被测模型用于 Ragas 评测与 Trace 判定，存在生成与裁判同源的偏差，即 self-Judge 限制。人工核验有助于暴露分歧，但作者自审没有替代独立复核。历史快照还缺少确切裁判版本、提示词版本和完整环境记录。

PASS 只说明指定样本达到保存门槛；默认 0.8 尚无业务校准证明。空 Trace 或缺失指标不能作为无幻觉证明。当前服务定位为本地评测与展示，真实评测采用同步请求，尚无生产所需的完整长任务管理和访问隔离。

本轮运行与待完成事项

2026-10-05 已通过当前 Web API 完成一次25题单模型正式运行，使用同一《存款保险条例》节选的固定案例集。请求 `deepseek-chat`，实际返回 `deepseek-flash`；Ragas 0.1.21、 `zh-sentence-v1`，325次完整调用、558,958 token。25条回答和五项指标均完整归档，Trace非空18条、空7条。正向 Faithfulness 0.7375 低于0.8，正向 Context Precision 0.9833 达到0.8，因此原始 Quality Gate 保留 FAIL。

正式运行公开证据包含输入、请求/响应、用量、指标、Trace、报告、运行源码和重新计算的哈希；离线分析表仅为 AI 辅助分析、待人工确认，不会更新 `credibility-review.json`。旧冻结 Demo 的13条作者核验仍只绑定旧快照。

本实验是单一金融材料的25题固定场景，部分题目共享法条，不是跨领域 Benchmark、统计独立样本或总体准确率证明。F类拒答、C02/D09指标与Trace差异、C03/D08低分和N03/N05拒答Trace差异均保留为可回查观察，原因未确认处不作推断。Trace和人工意见不直接触发当前门禁。

无密钥前端演示、真实 Web API 运行和旧快照模型复跑是不同证据；本轮没有新增模型调用授权。