# 鉴真全域 VeriScope AI 作品介绍

> 逐句核对与质量门禁平台

材料日期（PDF 导出）：2026-10-13；证据运行日期：2026-10-05。已完成工作与本轮实验的状态分别说明。

## 一、项目背景

AI 应用上线前，「回答是否可信」的判断往往停在一个平均分或肉眼抽查，既难以解释错误出现在哪一句，也难以据此判断是否达到放行要求。缺少的是**能逐句回查的依据。**

鉴真全域 VeriScope AI 面向 RAG 问答应用：把模型回答拆成逐句，每一句对照检索原文核对是否有依据，再由质量门禁（Quality Gate）按阈值决定这批回答能否放行。题集、检索上下文、模型回答、逐句判定、多模型指标、门禁记录与人工核验汇集到中文工作台，把「回答是否可信」变成一条可逐条回查的结论：

> 题集 → 逐句核对 → 门禁 → 报告 → 人工核验

## 二、创新点

本项目**不自研指标**：指标计算复用 Ragas，工作集中在指标层之上的三层——逐句证据、门禁裁决、人工核验存档，三者绑定在同一份冻结快照（SHA-256）上，可逐条回查。

| 层 | 内容 |
| --- | --- |
| 自研 | 逐句判定与证据定位；质量门禁裁决（保留真实 FAIL）；人工核验存档（人工意见与机器判定并列、互不覆盖）；中文陈述兼容层 `zh-sentence-v1` |
| 复用 | 指标计算 Ragas 0.1.21；检索与模型调用 LangChain、Chroma、OpenAI-compatible 接口；界面 React、ECharts；部署 Docker Compose（一键部署） |

| 现有方案 | 侧重 | 本项目与之的差异 |
| --- | --- | --- |
| Ragas | 指标计算（忠实度、上下文精度等） | 本项目**以 Ragas 为指标层**，在其上补逐句证据、门禁裁决与人工核验存档 |
| DeepEval | pytest 式断言，指标可设阈值，在 CI 中判定通过与否 | 阈值卡口不是本项目独有；差异在于门禁结论旁并列给出逐句核对证据，可回查到检索原文，并与人工核验分歧放在一起对照（逐句证据不参与门禁计算，门禁由正向忠实度与正向上下文精度决定）；面向中文陈述做了兼容 |
| TruLens | 运行时追踪与可观测（instrumentation） | 本项目聚焦**上线前的固定题集核对**，结论随冻结快照归档，而非运行时观测 |
| LLM Readiness Harness（2026 学术工作） | 面向 LLM / RAG 应用的 CI 质量门禁，把依据性、检索命中、成本、延迟等合成加权就绪分 | 同为上线前门禁，是最接近的已有工作；本项目的差异在于用冻结证据**检验门禁本身**是否可信（复算、换裁判、证据敏感性、结论确定性） |
| AWS Bedrock 依据检查 | 运行时护栏：给单条回答打「有无原文依据」「是否切题」两个分，低于阈值即拦截 | 它在运行时拦截单条回答；本项目在上线前按固定题集判定是否放行，并保留逐句证据与真实 FAIL |
| Azure 依据检测 | 用专门微调的判断模型标出无依据的句子，可选自动改写 | 它给出单条回答的检测结果；本项目不改写回答，重点是门禁结论可回查、可复算 |
| Google Vertex 依据核查 | 给回答一个 0–1 的支持度，可逐条陈述给出引用 | 逐句核对的思路相近；本项目在其上做门禁裁决，并审计门禁本身 |

以上比较基于各项目公开资料（Ragas、DeepEval、TruLens 核对日期 2026-10-11；其余 2026-10-13），不排除其内部已有类似实现；本项目不声称「业界唯一」。

具体创新点（均有实现）：

1. **逐句断言 + 证据回查**：把回答拆成原子陈述，逐句给出「有依据 / 事实错误 / 无依据编造」的原判定，并与对应检索原文并列呈现。

2. **质量门禁（Quality Gate）**：按正向忠实度与正向上下文精度双阈值（默认各 0.8）判定是否放行，并**保留真实 FAIL**、不隐藏。
3. **负向样本的拒答语义区分**：对文档未提及的问题，模型拒答属正确行为；系统按样本类型区分对待，避免把「正确拒答」误读为缺失或无法评估。
4. **人工核验存档**：人工结论与机器原判定**分列保存、互不覆盖**，核验材料绑定冻结快照版本与 SHA-256；存档结构有公开的 JSON Schema，并由测试校验。
5. **门禁可回放、可接入 CI**：已归档的运行可离线重新执行门禁裁决（不调用模型），裁决未通过时以非零退出码结束；门禁已打包为 GitHub Action，其他仓库一步接入，CI 页面以作业摘要和 JUnit 报告显示哪个指标未达标、差多少。指定基线后逐题对比上一次运行：按题重抽样求变化区间，并以同一裁判重判的实测波动为噪声底线，只有「确定退步」才拦截，在抽样与裁判波动范围内的下降只提示。
6. **报告可归档**：输出 CSV / HTML / Excel( XLSX ) / PDF 与图表，便于归档与评审。
7. **门禁可信度四问**：对门禁本身做审计——结论能否复算、换裁判会不会变、裁判是否依据证据、结论有多确定。25 题正式运行中，FAIL 可从逐句判定精确重现；换裁判后三次结论一致；按题重抽的 95% 区间为 55.0%–90.0%，跨过 0.8 门槛，属保守拦截而非确定不达标；固定 6 条陈述、只改变提供给裁判的证据（打乱、移除、改成矛盾），两个裁判 59 / 60 个有效判定全部符合作者确认的预期，另有 1 条解析失败如实保留待人工解释。每一问都可从冻结证据离线复算，见门禁可信度四问。门禁代码本身另由性质测试（10 条性质）与变异测试检验：42 个人工改坏的变异中测试抓住 39 个，存活的 3 个均不影响放行结论。工作台「门禁审计」页把这些结果集中展示，数据由冻结证据生成并核对哈希。
8. **失败归因：该修检索还是生成**：门禁拦截后，按逐题指标把正向忠实度的差距拆到检索（未找全、排序差）与生成（拒答、无依据）两段，写入 CI 作业摘要并给出修改建议，不影响裁决。25 题正式运行的 FAIL 全部来自 4 道错误前提题：检索召回均为 1.0，原文已找到，模型却拒答而没有依据原文纠正前提。这 4 题合计拉低正向忠实度 0.2，该修的是问答提示，不是检索。
9. **逐句核对的外部基准**：用两个公开、带人工标注的中文数据集检验逐句核对本身，直接调用生产代码，付费运行一次。
    - ANAH（ACL 2024）人工逐句标注 300 句：幻觉召回率 0.89，精确率 0.87，按实际比例折算约 0.72。核对比人工更严，宁可多标。
    - RGB（AAAI 2024）新闻领域 100 题：40 个正确回答 0 误判；资料无关时拒答 87.5%；资料本身写错时，照抄的回答多半仍判为有依据（11 题标出 3 题）。这是忠实度核对的固有边界，已如实写入文档。
    - 仓库只存编号与判定，审计页用逐条判定重算汇总并核对哈希，见 外部基准验证。
10. **鲁棒性体检：可用于任何 RAG 应用**：把证据敏感性实验做成产品功能。
    - 方法：不用模型自动定位依据资料，构造打乱、加噪、移除依据、反事实四种资料条件；同时检验被测应用会不会被资料带偏，以及逐句核对是否跟着证据走。被测应用可通过 HTTP 接口接入。
    - 2026-10-13 在 20 道正向题上运行一次（约 ¥0.47）：核对侧 58 项中 57 项符合预期；应用在移除依据后拒答 19 / 20，反事实条件下没有一题沿用原值。
    - 详见 鲁棒性体检。
11. **把裁判误差也算进门禁区间**：门禁区间原先把每条逐句判定都当作正确。
    - 方法：实现 Lee et al.（ICML 2026）的校准校正，并推广到按题聚集的陈述；另实现预测驱动推断（PPI）。
    - 模拟：在本次题目结构下，只计题目抽样的区间实际覆盖率只有 3%–53%，按题聚集的校正为 94%–96%。
    - 敏感性：作答题中判为不支持的陈述只有 5 条，要全部改判才到 80%。
    - 现阶段：已实现裁判误差分析工具和模拟验证，真实人工校准待完成。门禁裁判的真实误差待非作者人工标注（52 条，标注页与分析工具已就绪），完成前不报告校正后的结论。详见 裁判判错校准。

## 三、技术架构

## 鉴真全域 VeriScope AI · 技术架构




说明：前端演示基于冻结快照；真实评测需在本地配置模型密钥后运行，评测为同步请求
本图仅表示模块与数据流向，不代表性能或部署承诺。

| 模块 | 技术与职责 |
| --- | --- |
| Frontend | React 19、TypeScript、Vite、Apache ECharts；首页与七个工作台视图 |
| Backend | Python、FastAPI；参数与路径校验、同步评测调用、结果序列化 |
| Evaluation Pipeline | LangChain、Chroma、本地 Embedding、Ragas；文档 → 测试集 → 检索与回答 → 指标与溯源 → 门禁与报告 |
| Model Adapter | OpenAI-compatible 适配；DeepSeek、Qwen2.5-7B、GLM-5.2-Fast |

| 模块 | 技术与职责 |
| --- | --- |
| Compatibility | 保留 CLI 与 Gradio 入口；报告、存储、服务与核心评测在 `backend/` 分层 |

评测链路为：文档 → 测试集 → 检索 → 问答 → 指标 → 溯源 → 门禁 → 报告 → 复核。

## 四、应用场景与实际使用案例

### 应用场景：RAG 应用上线验收

对智能问答、知识库问答等 RAG 应用，在上线前用固定测试集跑一次评测，由质量门禁判定是否放行；未通过时，逐句溯源定位到「哪一句、依据哪段上下文、判定是什么」，便于修复与复评。

**典型用法：上线前接入 CI 作回归门禁**；已归档运行可离线重放门禁，不通过即以非零退出码阻断（见 quality-gate-example.yml）。

### 实际使用案例（仅引用已有运行证据）

- **案例一：25 题单模型正式运行（证据运行日期 2026-10-05）**
  使用《存款保险条例》节选的固定案例集，正向 Faithfulness **0.7375 低于 0.8**，正向 Context Precision 0.9833 达到 0.8 → 原始 Quality Gate **保留 FAIL**。即：**该次评测被门禁拦下**，且完整回答、contexts、指标、Trace、报告与哈希均已归档，可逐条回查失败原因。
- **案例二：历史金融场景旧 CLI 运行**
  正向上下文精度 **0.7778 低于 0.8** → FAIL；该案例与当前演示快照分开保存。

> 两个案例均为**真实运行**：门禁把未达标的评测挡在发布前，逐句溯源给出具体语句与证据。

**用了本平台具体好在哪。** 对案例一，只看 Ragas 总分是 0.59，因为 5 道正确拒答的负向题被算作 0 分。本平台分开正负样本，得出正向题 0.7375；逐句核对确认作答题的 40 条陈述都有原文依据；逐题归因指出拦截的 76% 来自 4 道错误前提题的拒答，该修提示词而不是检索；区间 55.0%–90.0% 跨过门槛，说明这是保守拦截。逐项对照见 同一次 FAIL 的三种看法。使用者计时对照尚未完成。

- **案例三（外部项目）：Langchain-Chatchat 默认知识库提示词（2026-10-14）**
  同一模型、同一批资料，只换问答提示词，比较 Langchain-Chatchat（Apache-2.0）的默认模板与本项目自己的提示。5 道错误前提题中，它拒答 2 道，本项目提示拒答 3 道；F03、F04 两道资料里有纠正所需的原文（「每6个月交纳一次保费」的主体是投保机构、「7个工作日内足额偿付」），两种提示都回答「无法回答」。资料无答案的 5 道题两者都正确拒答，作答的陈述逐句核对全部有原文依据。这说明失败归因发现的问题（只给拒答一个出口的提示词，遇到错误前提会拒答）在外部项目上同样存在。只测了默认提示词，不代表该项目实际部署的效果；本次未测试修改后的提示词。经授权运行，100 次请求，约 ¥0.15。详见 外部案例。

## 五、现有证据与运行记录

### 1. 无密钥演示快照（演示数据）

冻结快照 `20260930-1958`：**6 个问题、3 个模型、18 条回答**——这是用于离线展示流程的**演示数据**，非真实业务结论；演示快照、三模型对比图表均**仅代表演示数据**。前端依赖准备后可在本地无需模型密钥、Embedding 或后端展示，不产生模型调用费用。

### 2. 25 题正式运行（证据运行日期 2026-10-05）

- 请求模型 `deepseek-chat`，**实际返回模型为 `deepseek-flash`**（如实记录）。按 DeepSeek 官方模型 & 价格页与 2026-09-10 更新日志，`deepseek-flash` 对应 **DeepSeek-V4.1-Flash**。接口不返回不可变的版本号，这里依据的是官方公布的名称对应关系。
- Ragas 0.1.21、`zh-sentence-v1`；**325 次完整调用、558,958 token**。
- 25 条回答与五项指标均 25/25 完整归档；**Trace 非空 18 条、空 7 条**。
- 正向 Faithfulness **0.7375**（低于 0.8）、正向 Context Precision **0.9833**（达到 0.8）→ **原始 Quality Gate 保留 FAIL**。

证据链接：正式运行公开证据、离线分析表（后者为 AI 辅助分析、待人工确认）。

### 3. 人工核验（13 条定向记录）

作者于 2026-10-05 逐条检查其中 13 条定向记录，结果为 **一致 3 条、存在分歧 5 条、无法确认 5 条**。

> **核验发现较多分歧（5/13），说明 self-Judge（生成与裁判同源）存在局限**——这也是「独立裁判」被列为路线图第一项的原因。核验仅覆盖冻结演示快照的 13 条定向样本，**不能据此计算总体准确率**，也不代表独立复核或系统认证。

### 4. 外部基准验证（2026-10-13）

- 数据：ANAH 中文部分（Apache-2.0）300 句，RGB 中文部分（CC BY-NC-SA 4.0，仅非商业）100 题。版本固定，源文件哈希逐一核对，原文不入库。
- 调用：500 次请求，经单独授权，不重试；按返回用量估算约 ¥2.68，不是账单。请求模型 `deepseek-chat`，实际返回 `deepseek-flash`（DeepSeek-V4.1-Flash）。
- 结果：
- ANAH：召回率 0.89（95% 区间 0.84–0.93），精确率 0.87（等量抽样；按实际比例折算约 0.72），特异度 0.73。
- RGB：噪声条件 40 题全对、0 误判；应拒答条件拒答 35 / 40；反事实条件只给错误答案的 11 题标出 3 题。

证据链接：外部基准验证。

### 5. 鲁棒性体检（2026-10-13）

- 对象：25 题正式运行的 20 道正向题；260 次请求，经单独授权，不重试；按返回用量估算约 ¥0.47。
- 结果：
- 核对侧：移除依据后 16 / 16 标出，反事实 9 / 10 判为矛盾，打乱与加噪不改变结论。
- 生成侧：移除依据后拒答 19 / 20，反事实条件下 0 题沿用原值。

证据链接：鲁棒性体检。

## 六、技术限制与诚实边界

- **self-Judge**：当前后端会将相应被测模型用于 Ragas 评测与 Trace 判定，存在生成与裁判同源的偏差；人工核验有助于暴露分歧，但作者自审不能替代独立复核。已做一次量化对照（2026-10-11）：换用 Qwen2.5-72B 作为独立裁判重判 25 题，门禁结论不变（FAIL）；但逐题 Faithfulness 平均绝对差为 0.095，是原裁判自我重判（0.017）的约 5–6 倍；Trace 标签一致率为 72%，原裁判重判为 92%。分歧集中在原本为空的 Trace，需要人工核查，不能判定哪个裁判正确。
- **阈值未业务校准**：默认 0.8 尚无业务校准证明；PASS 仅说明指定样本达到保存门槛，不代表所有指标优秀或每条回答正确。
- **无鉴权与访问隔离**：当前服务定位为本地评测与展示，缺少生产所需的访问控制；公开演示站为只读，不开放在线评测。
- **同步评测**：真实评测采用同步请求，尚无生产所需的完整长任务管理与进度接口。
- **空 Trace 不等于无幻觉**：空 Trace 或缺失指标不能作为无幻觉证明；逐句判定依赖原始溯源记录，不是额外的独立真实性保证。
- **样本范围**：25 题为单一金融材料的固定场景，部分题目共享法条，**不是跨领域 Benchmark、统计独立样本或总体准确率证明**。外部基准是两个公开数据集上的单次、单裁判抽样检验，同样不代表总体准确率。
- **裁判误差待人工标注**：已实现裁判误差分析工具和模拟验证，真实人工校准待完成。模拟中的裁判误差借用 ANAH 实测值，门禁裁判的真实误差要靠非作者人工标注估计。
- **资料本身的错误查不出**：逐句核对检查回答与检索资料是否一致，不检查资料是否正确；外部基准中资料写错时，照抄的回答多半被判为有依据。
- 历史快照还缺少确切的裁判版本、提示词版本与完整环境记录。

## 七、开源治理与长期发展

### 开源治理

- **许可**：本项目自有代码按 MIT License 发布；第三方代码与依赖适用各自许可，见 `frontend/THIRD_PARTY_NOTICES.md` 与 `frontend/licenses/`。
- **文档**：README、CONTRIBUTING、CHANGELOG、架构文档、演示指南与评测可信度说明齐备。
- **合规**：密钥只存放于本地 `.env` 或环境变量，不入库；`.env.example` 为空模板。
- **贡献机制**：欢迎问题报告、文档改进与有验证依据的改动（见 CONTRIBUTING.md）。

### 长期发展

- **团队**：1 人（负责人 1 名）。
- **维护人**：LI。
- **Issue / PR 响应承诺**：**3 个工作日内首次回复。**
- **未来 3 个月路线图**（各项目标日期与验收方式见 ROADMAP）：
  1. **独立裁判**：已完成一次对照实验，量化了同源偏差；下一步把裁判做成可配置项，并扩大样本、重复运行。
  2. **门禁阈值的业务校准**：用人工标注数据校准 0.8 阈值。
  3. **评测任务队列与进度接口。**

4. **鉴权与访问隔离**（云部署前提）。
5. **多领域基准集。**