鉴真全域 VeriScope AI 作品介绍

> 逐句核对与质量门禁平台：AI 的每个回答，都能逐句查到出处。

材料日期：2026-10-14。证据运行：2026-10-05 正式运行，2026-10-14 修复后重跑。代码仓库：Gitee（主） · GitHub（镜像）。

一、要解决的问题

RAG 问答应用上线前，「回答是否可信」通常只看一个平均分，或者人工抽查几条。这样说不清错在哪一句，也说不清这批回答能不能放行。

本平台的做法分三步：

1. 把模型回答拆成逐句；
2. 每一句对照检索原文，核对有没有依据；
3. 由质量门禁（Quality Gate）按阈值决定这批回答能否放行。

题集、检索原文、回答、逐句判定、指标、门禁记录和人工核验保存在同一条链路上，可以逐条回查：

> 题集 → 逐句核对 → 门禁 → 报告 → 人工核验

二、创新点

本项目**不自研指标**，指标计算复用 Ragas，工作集中在指标之上：

层	内容
自研	逐句判定与证据定位；质量门禁（保留真实 FAIL）；人工核验存档（与机器判定并列、互不覆盖）；中文陈述兼容层
复用	Ragas 0.1.21；LangChain、Chroma、OpenAI 兼容接口；React、ECharts；Docker Compose

与已有方案的区别：

- **Ragas**：只算指标。本项目以它为指标层，在上面加逐句证据、门禁和人工核验。

- **DeepEval**：也能在 CI 里按阈值卡口。本项目的不同在于门禁结论旁边并列逐句证据，能回查到检索原文。
- **最接近的已有工作**：LLM Readiness Harness，同样是上线前门禁。本项目进一步**检验门禁本身是否可信**。

以上比较基于各项目公开资料（核对日期 2026-10-11 至 10-13），本项目不声称「业界唯一」。

主要能力（均已实现）：

1. **逐句核对与证据回查**：每句给出「有依据 / 事实错误 / 无依据编造」的判定，并和对应原文并排展示。
2. **质量门禁**：正向忠实度与正向上下文精度两个阈值（默认各 0.8）。区分正负样本，正确拒答不被当成 0 分。
3. **门禁接入 CI**：已归档的运行可以离线重放门禁，不调用模型；未通过时以非零退出码阻断构建。指定基线后逐题对比，只有「确定退步」才拦截。
4. **失败归因**：门禁拦截后，判断该修检索还是该修生成，并给出修改建议。
5. **门禁可信度审计**：检查四个问题——结论能否复算、换裁判会不会变、裁判是否依据证据、结论有多确定。详见 门禁可信度四问。
6. **鲁棒性体检**：打乱、加噪、移除依据、反事实四种资料条件，检验被测应用和逐句核对是否跟着证据走。被测应用可以通过 HTTP 接口接入。详见 鲁棒性体检。
7. **外部基准验证**：用两个带人工标注的公开中文数据集检验逐句核对。ANAH 召回率 0.89、精确率 0.87；RGB 40 个正确回答 0 误判。详见 外部基准验证。
8. **自有模型与内网部署**：任何 OpenAI 兼容接口（vLLM、Ollama、内部网关）在「模型配置」页登记即可参评，密钥只留在本机。详见 落地与接入。

三、实际案例：发现问题 → 修复 → 验证

1. 发现（2026-10-05）。 用《存款保险条例》节选的 25 题正式运行（`deepseek-chat`，325 次调用）：

- 正向忠实度 **0.7375**，低于 0.8，门禁 **FAIL**，评测被拦在发布前。
- 只看 Ragas 总分是 0.59，因为 5 道正确拒答的负向题被算作 0 分；本平台分开正负样本，才得出 0.7375。

2. 归因。 逐句核对显示：作答题的 40 条陈述都有原文依据。拦截的 76% 来自 4 道「错误前提」题。这几道题的检索原文里有纠正所需的法条，模型却直接回答「无法回答」。结论是该修问答提示词，不是检索。

3. 修复（2026-10-14）。 在问答提示词里加了一句：「问题的说法或前提与参考资料不一致时，依据资料指出并纠正，不要拒答」。

4. 验证。 同一题集、同一资料、同一模型重跑 25 题；门禁、阈值、裁判都没有改。

- 正向忠实度 0.7375 → **0.8607**，门禁 **FAIL → PASS**。
- 4 道错误前提题纠正了 3 道，F04 仍然拒答。
- 资料里没有答案的 5 道题仍全部正确拒答。
- 以原 FAIL 为基线逐题回归对比，未发现退步。

局限： 修复是在发现问题的同一批题上验证的，只跑了一次，离阈值只有约 0.06，不能代表在新题上的效果。证据见 正式运行、修复验证。

外部项目（2026-10-14）。 用同样的方法检验了 Langchain-Chatchat 的默认知识库提示词。5 道错误前提题中，它拒答 2 道，说明同类问题在外部项目中同样存在。只测了默认提示词，不代表其实际部署效果。已向该项目提交 Issue。详见 外部案例。

四、证据一览

日期	内容（点击查看证据）	结果
10-05	25 题正式运行	门禁 FAIL（0.7375）
10-11	换独立裁判（Qwen2.5-72B）重判	结论不变，逐题分数差异约为自我重判的 5–6 倍
10-13	外部基准（ANAH 300 句、RGB 100 题）	召回率 0.89，精确率 0.87
10-13	鲁棒性体检（20 题 × 4 种条件）	移除依据后应用拒答 19/20
10-14	本机无外网试跑（Ollama 2B）	外网连接尝试 0 次
10-14	修复后重跑 25 题	门禁 PASS（0.8607）

每次付费运行都经过单独授权，原始结果连同哈希一起归档，可以离线复算。

五、限制与诚实边界

- **裁判同源**：被测模型同时担任裁判，存在偏差。换独立裁判后门禁结论不变，但逐题差异明显。
- **裁判误差待人工标注**：误差分析工具已就绪，真实误差需要非作者人工标注 52 条陈述；完成前不报告校正后的结论。
- **样本范围**：25 题来自同一份金融材料，不是跨领域基准，也不代表总体准确率。
- **阈值未经业务校准**：PASS 只说明样本达到设定门槛，不代表每条回答都正确。
- **资料本身的错误查不出**：逐句核对只检查回答和资料是否一致，不检查资料本身对不对。
- **部署**：当前没有鉴权，评测是同步请求；公开演示站只读，不开放在线评测。

六、开源治理与路线图

- **许可**：自有代码 MIT；第三方依赖适用各自许可。
- **治理**：README、CONTRIBUTING、CHANGELOG、安全策略、行为准则齐备；CI、CodeQL、Scorecard 在 GitHub 镜像运行。
- **维护**：1 人（LI）；Issue / PR 承诺 3 个工作日内首次回复。
- **未来 3 个月**（详见 ROADMAP）：
  1. 独立裁判做成可配置项；
  2. 用人工标注校准门禁阈值；
  3. 评测任务队列与进度接口；
  4. 鉴权与访问隔离；
  5. 多领域基准集。

七、技术架构



说明：前端演示基于冻结快照；真实评测需在本地配置模型密钥后运行，评测为同步请求。第三方组件与依赖按各自许可使用。

本图仅表示模块与数据流向，不代表性能或部署承诺。