鉴真全域 VeriScope AI 作品介绍

> AI 测试交付与质量门禁平台

材料日期（PDF 导出）：2026-10-09；证据运行日期：2026-10-05。已完成工作与本轮实验的状态分别说明。

一、项目背景

AI 应用上线前，「回答是否可信」的判断往往停在一个平均分或肉眼抽查，既难以解释错误出现在哪里，也难以据此判断是否达到发布要求。缺少的是一套**可交付、可复用**的测试结论。

鉴真全域 VeriScope AI 面向 AI 应用（当前以 RAG 问答为测试对象）的测试交付，把测试用例集、检索上下文、模型回答、逐句断言、多模型指标、质量门禁（Quality Gate）与人工复核汇集到中文工作台，把「回答是否可信」变成一条可逐条回查的结论：

> 用例 → 断言 → 门禁 → 报告 → 复核

二、创新点

与现有主流方案相比，本项目的差异在于**把指标计算补齐为一条可交付、可复核的测试链路**：

现有方案	侧重	本项目与之的差异
Ragas	指标计算（忠实度、上下文精度等）	本项目**以 Ragas 为指标层**，向上补齐「逐句断言 → 质量门禁 → 报告交付 → 人工复核」闭环
DeepEval	LLM「单元测试」式断言、偏英文与通用用例	本项目面向**中文**，以**证据可回查**为核心，把回答拆成原子陈述并保留判定与检索原文
TruLens	运行时追踪与可观测（instrumentation）	本项目聚焦**上线前的测试交付**，输出可归档、可门禁、可复核的测试结论，而非运行时观测

具体创新点（均有实现）：

1. **逐句断言 + 证据回查**：把回答拆成原子陈述，逐句给出「有依据 / 事实错误 / 无依据编造」的原判定，并与对应检索原文并列呈现。
2. **质量门禁（Quality Gate）**：按正向忠实度与正向上下文精度双阈值（默认各 0.8）判定是否放行，并**保留真实 FAIL**、不隐藏。
3. **负向样本的拒答语义区分**：对文档未提及的问题，模型拒答属正确行为；系统按样本类型区分对待，避免把「正确拒答」误读为缺失或无法评估。
4. **人工复核模块**：人工结论与机器原判定**分列呈现**，核验材料绑定冻结快照版本与 SHA-256，便于追溯。
5. **测试结论可交付**：输出 CSV / HTML / Excel(XLSX) / PDF 与图表，便于归档与评审。

三、技术架构

鉴真全域 VeriScope AI • 技术架构



说明：前端演示基于冻结快照；真实评测需在本地配置模型密钥后运行，评测为同步请求
本图仅表示模块与数据流向，不代表性能或部署承诺。

模块	技术与职责
Frontend	React 19、TypeScript、Vite、Apache ECharts；首页与六个工作台视图
Backend	Python、FastAPI；参数与路径校验、同步评测调用、结果序列化
Evaluation Pipeline	LangChain、Chroma、本地 Embedding、Ragas；文档 → 测试集 → 检索与回答 → 指标与溯源 → 门禁与报告
Model Adapter	OpenAI-compatible 适配；DeepSeek、Qwen2.5-7B、GLM-5.2-Fast

模块	技术与职责
Compatibility	保留 CLI 与 Gradio 入口；报告、存储、服务与核心评测在 `backend/` 分层

评测链路为：文档 → 测试集 → 检索 → 问答 → 指标 → 溯源 → 门禁 → 报告 → 复核。

四、应用场景与实际使用案例

应用场景：RAG 应用上线验收

对智能问答、知识库问答等 RAG 应用，在上线前用固定测试集跑一次评测，由质量门禁判定是否放行；未通过时，逐句溯源定位到「哪一句、依据哪段上下文、判定是什么」，便于修复与复评。

实际使用案例（仅引用已有运行证据）

- **案例一：25 题单模型正式运行（证据运行日期 2026-10-05）**
  使用《存款保险条例》节选的固定案例集，正向 Faithfulness **0.7375 低于 0.8**，正向 Context Precision 0.9833 达到 0.8 → 原始 Quality Gate **保留 FAIL**。即：**该次评测被门禁拦下**，且完整回答、contexts、指标、Trace、报告与哈希均已归档，可逐条回查失败原因。
- **案例二：历史金融场景旧 CLI 运行**
  正向上下文精度 **0.7778 低于 0.8** → FAIL；该案例与当前演示快照分开保存。

> 两个案例均为**真实运行**：门禁把未达标的评测挡在发布前，逐句溯源给出具体语句与证据。

五、现有证据与运行记录

1. 无密钥演示快照（演示数据）

冻结快照 `20260930-1958`：**6 个问题、3 个模型、18 条回答**——这是用于离线展示流程的**演示数据**，非真实业务结论；演示快照、三模型对比图表均**仅代表演示数据**。前端依赖准备后可在本地无需模型密钥、Embedding 或后端展示，不产生模型调用费用。

2. 25 题正式运行（证据运行日期 2026-10-05）

- 请求模型 `deepseek-chat`，**实际返回模型为 `deepseek-flash`**（如实记录）。
- Ragas 0.1.21、`zh-sentence-v1`；**325 次完整调用、558,958 token。**
- 25 条回答与五项指标均 25/25 完整归档；**Trace 非空 18 条、空 7 条。**
- 正向 Faithfulness **0.7375**（低于 0.8）、正向 Context Precision **0.9833**（达到 0.8）→ **原始 Quality Gate 保留 FAIL。**

证据链接：正式运行公开证据、离线分析表（后者为 AI 辅助分析、待人工确认）。

3. 人工核验（13 条定向记录）

作者于 2026-10-05 逐条检查其中 13 条定向记录，结果为 **一致 3 条、存在分歧 5 条、无法确认 5 条。**

> **核验发现较多分歧（5/13），说明 self-Judge（生成与裁判同源）存在局限**——这也是「独立裁判」被列为路线图第一项的原因。核验仅覆盖冻结演示快照的 13 条定向样本，**不能据此计算总体准确率**，也不代表独立复核或系统认证。

六、技术限制与诚实边界

- **self-Judge**：当前后端会将相应被测模型用于 Ragas 评测与 Trace 判定，存在生成与裁判同源的偏差；人工核验有助于暴露分歧，但作者自审不能替代独立复核。
- **阈值未业务校准**：默认 0.8 尚无业务校准证明；PASS 仅说明指定样本达到保存门槛，不代表所有指标优秀或每条回答正确。
- **无鉴权与访问隔离**：当前服务定位为本地评测与展示，缺少生产所需的访问控制。
- **同步评测**：真实评测采用同步请求，尚无生产所需的完整长任务管理与进度接口。
- **空 Trace 不等于无幻觉**：空 Trace 或缺失指标不能作为无幻觉证明；逐句判定依赖原始溯源记录，不是额外的独立真实性保证。
- **样本范围**：25 题为单一金融材料的固定场景，部分题目共享法条，**不是跨领域 Benchmark、统计独立样本或总体准确率证明。**
- 历史快照还缺少确切的裁判版本、提示词版本与完整环境记录。

七、开源治理与长期发展

开源治理

- **许可**：本项目自有代码按 MIT License 发布；第三方代码与依赖适用各自许可，见 `frontend/THIRD_PARTY_NOTICES.md` 与 `frontend/licenses/`。
- **文档**：README、CONTRIBUTING、CHANGELOG、架构文档、演示指南与评测可信度说明齐备。
- **合规**：密钥只存放于本地 `.env` 或环境变量，不入库；`.env.example` 为空模板。
- **贡献机制**：欢迎问题报告、文档改进与有验证依据的改动（见 CONTRIBUTING.md）。

长期发展

- **团队**：1 人（负责人 1 名）。
- **维护人**：LI。
- **Issue / PR 响应承诺**：**3 个工作日内首次回复。**
- **未来 3 个月路线图**：
  1. **独立裁判**：引入不同来源的模型做交叉评分，解决 self-Judge。
  2. **门禁阈值的业务校准**：用人工标注数据校准 0.8 阈值。
  3. **评测任务队列与进度接口。**
  4. **鉴权与访问隔离**（云部署前提）。
  5. **多领域基准集。**